Modelos ARIMA y SARIMA

Identificación, Estimación y Diagnóstico

Aplicación al Índice Bursátil S&P 500

Alumna: Regina Flores Chávez

Materia: Series de Tiempo

Carrera: Finanzas Cuantitativas

Institución: Universidad Panamericana

Fecha: Abril 2026

Contents

1 Marco Teórico **2**
- 1.1 Procesos Autoregresivos AR(p) . . . 2
- 1.2 Procesos de Medias Móviles MA(q) . . . 2
- 1.3 Procesos ARMA(p, q) . . . 2
- 1.4 Modelos ARIMA(p, d, q) . . . 2
- 1.5 Modelos SARIMA(p,d,q)(P,D,Q)$_s$ . . . 3
- 1.6 Función de Autocorrelación (ACF) . . . 3
- 1.7 Función de Autocorrelación Parcial (PACF) . . . 4
- 1.8 Criterios de Información: AIC y BIC . . . 4

2 Base de Datos **4**
- 2.1 Descripción de la serie . . . 5
- 2.2 Exploración de la serie . . . 6

3 Análisis de Estacionariedad **6**
- 3.1 Concepto de estacionariedad . . . 6
- 3.2 Prueba de Raíz Unitaria (Dickey-Fuller Aumentada) . . . 7
- 3.3 Análisis visual de estacionariedad . . . 7
- 3.4 Correlogramas en nivel y en diferencia . . . 8

4 Ejemplo 1: Modelo ARIMA(1,1,1) **8**
- 4.1 Identificación del modelo . . . 8
- 4.2 Especificación matemática . . . 9
- 4.3 Código Python . . . 9
- 4.4 Resultados gráficos . . . 11
- 4.5 Interpretación del pronóstico . . . 11

5 Ejemplo 2: Comparación de Modelos con AIC y BIC **12**
- 5.1 Metodología de selección . . . 12
- 5.2 Por qué el BIC puede diferir del AIC . . . 12
- 5.3 Código Python . . . 12
- 5.4 Resultados gráficos . . . 13

6 Ejemplo 3: Modelo SARIMA con Componente Estacional **14**
- 6.1 Motivación y patrón estacional . . . 14
- 6.2 Identificación del modelo SARIMA . . . 14
- 6.3 Especificación matemática . . . 14
- 6.4 Código Python . . . 15
- 6.5 Resultados gráficos . . . 16
- 6.6 Interpretación del pronóstico . . . 16

7 Comparación Final de los Tres Ejemplos **17**

8 Metodología Box-Jenkins: Diagrama de Flujo **18**

9 Conclusiones **18**

1 Marco Teórico

1.1 Procesos Autoregresivos AR(p)

Un proceso **autoregresivo de orden** p, denotado AR(p), expresa el valor actual de la serie como combinación lineal de sus p valores pasados más un término de error:

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t, \qquad \varepsilon_t \sim \mathcal{N}(0, \sigma^2) \tag{1}$$

donde c es una constante y $\{\phi_i\}$ son los coeficientes autorregresivos.

Usando el operador de rezago B tal que $B^k y_t = y_{t-k}$, se escribe:

$$\phi_p(B)\, y_t = c + \varepsilon_t, \quad \phi_p(B) = 1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p \tag{2}$$

El proceso es **estacionario** si todas las raíces del polinomio $\phi_p(z) = 0$ caen *fuera* del círculo unitario.

1.2 Procesos de Medias Móviles MA(q)

Un proceso **de medias móviles de orden** q, denotado MA(q), expresa y_t como combinación lineal de q términos de error pasados:

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} = \mu + \theta_q(B)\, \varepsilon_t \tag{3}$$

con $\theta_q(B) = 1 + \theta_1 B + \cdots + \theta_q B^q$.

Todo proceso MA(q) es estacionario; la **invertibilidad** requiere que las raíces de $\theta_q(z) = 0$ estén fuera del círculo unitario.

1.3 Procesos ARMA(p, q)

La combinación de ambos componentes da lugar al modelo **ARMA**:

$$\phi_p(B)\, y_t = c + \theta_q(B)\, \varepsilon_t \tag{4}$$

El ARMA requiere que la serie sea *estacionaria* (proceso ya en nivel).

1.4 Modelos ARIMA(p, d, q)

Cuando la serie no es estacionaria, se aplican d diferenciaciones regulares $\nabla^d = (1 - B)^d$. El modelo **ARIMA**(p, d, q) es:

$$\phi_p(B)\, \underbrace{(1 - B)^d\, y_t}_{\tilde{y}_t} = c + \theta_q(B)\, \varepsilon_t \tag{5}$$

Table 1: Parámetros del modelo ARIMA(p, d, q)

Par.	Nombre	Interpretación y herramienta de identificación
p	Orden AR	Número de rezagos autoregresivos. Se identifica con la **PACF** (corte abrupto en el rezago p)
d	Integración	Número de diferencias para lograr estacionariedad. Se determina con prueba ADF/KPSS
q	Orden MA	Número de rezagos de medias móviles. Se identifica con la **ACF** (corte abrupto en el rezago q)

1.5 Modelos SARIMA$(p,d,q)(P,D,Q)_s$

El modelo **SARIMA** extiende el ARIMA incorporando componentes estacionales de periodo s:

$$\boxed{\underbrace{\Phi_P(B^s)}_{\text{AR estacional}}\ \underbrace{\phi_p(B)}_{\text{AR regular}}\ \underbrace{(1-B^s)^D}_{\text{dif. estacional}}\underbrace{(1-B)^d}_{\text{dif. regular}}\ y_t \ = \ \underbrace{\Theta_Q(B^s)}_{\text{MA estacional}}\ \underbrace{\theta_q(B)}_{\text{MA regular}}\ \varepsilon_t} \tag{6}$$

donde $\Phi_P(B^s) = 1 - \Phi_1 B^s - \cdots - \Phi_P B^{Ps}$ y $\Theta_Q(B^s) = 1 + \Theta_1 B^s + \cdots + \Theta_Q B^{Qs}$.

Table 2: Parámetros del modelo SARIMA$(p, d, q)(P, D, Q)_s$

Par.	Componente	Herramienta	Descripción
p	AR regular	PACF (rezagos no estacionales)	Dependencia de corto plazo
d	I regular	Prueba ADF / diferenciación	Elimina tendencia
q	MA regular	ACF (rezagos no estacionales)	Corrección de corto plazo
P	AR estacional	PACF (múltiplos de s)	Dependencia estacional
D	I estacional	Diferencia estacional $(1-B^s)^D$	Elimina estacionalidad
Q	MA estacional	ACF (múltiplos de s)	Corrección estacional
s	Periodo	Inspección visual / dominio	Longitud del ciclo (e.g. $s = 12$ mensual)

1.6 Función de Autocorrelación (ACF)

La **ACF** al rezago k mide la correlación lineal entre y_t y y_{t-k}:

$$\rho_k = \frac{\mathrm{Cov}(y_t,\, y_{t-k})}{\mathrm{Var}(y_t)} = \frac{\gamma_k}{\gamma_0}, \qquad k = 0, 1, 2, \ldots \tag{7}$$

El intervalo de confianza aproximado al 95% para $\hat{\rho}_k$ bajo $H_0 : \rho_k = 0$ es $\pm 1.96/\sqrt{n}$.

Uso en identificación: la ACF de un MA(q) se corta *abruptamente* después del rezago q; la de un AR(p) decae de forma exponencial o sinusoidal.

1.7 Función de Autocorrelación Parcial (PACF)

La **PACF** al rezago k mide la correlación entre y_t e y_{t-k} eliminando el efecto de los rezagos intermedios (esperanza condicional):

$$\phi_{kk} = \mathrm{Corr}(y_t,\, y_{t-k} \mid y_{t-1}, \ldots, y_{t-k+1}) \tag{8}$$

Se obtiene como último coeficiente en la regresión de Yule-Walker de orden k. La PACF de un AR(p) se corta después del rezago p; la de un MA(q) decae.

Table 3: Patrones de ACF/PACF para la identificación del modelo

Proceso	ACF	PACF
AR(p)	Decaimiento gradual (exp. o sin.)	Corte abrupto en rezago p
MA(q)	Corte abrupto en rezago q	Decaimiento gradual
ARMA(p, q)	Decaimiento gradual	Decaimiento gradual
Ruido blanco	Sin autocorrelación	Sin autocorrelación parcial
No estacion.	Decaimiento muy lento (ACF alta)	Primer rezago ≈ 1

1.8 Criterios de Información: AIC y BIC

Los criterios de información permiten comparar modelos con distinto número de parámetros penalizando la complejidad:

$$\mathrm{AIC} = -2 \ln \hat{L} + 2k \tag{9}$$

$$\mathrm{BIC} = -2 \ln \hat{L} + k \ln(n) \tag{10}$$

donde $\hat{L}$ es la verosimilitud maximizada, k el número de parámetros y n el tamaño de muestra. En ambos casos **se minimiza el criterio**. El BIC penaliza más fuertemente los modelos complejos cuando n es grande, favoreciendo modelos más parsimonios (principio de parsimonia: $p + d + q + P + D + Q \leq C$).

2 Base de Datos

2.1 Descripción de la serie

Table 4: Ficha técnica de la base de datos

Atributo	Detalle
Serie	S&P 500 — Índice bursátil de las 500 empresas más grandes de EE.UU.
Ticker	`^GSPC` (Yahoo Finance)
Periodo	Enero 2018 — Diciembre 2023 (72 meses)
Frecuencia	Mensual (precio promedio del mes a partir de datos diarios)
Variable	Precio de cierre ajustado (USD); se trabaja con el log-precio
Fuente	Yahoo Finance (`yfinance` API)
Observ.	72 observaciones mensuales; 1,512 observaciones diarias
Transformación	$y_t = \ln(P_t)$; primera diferencia $\nabla y_t = \ln(P_t) - \ln(P_{t-1})$

Justificación de la transformación logarítmica: al trabajar con $\ln(P_t)$ se estabiliza la varianza (heterocedasticidad), se lineariza el crecimiento exponencial y $\nabla \ln(P_t) \approx r_t$ representa el retorno continuo del periodo, que es la variable relevante en finanzas.

Contexto económico: el periodo 2018–2023 incluye la guerra comercial EE.UU.–China (2018–2019), el crash y rebote por COVID-19 (2020), la expansión fiscal post-pandemia (2021) y el ciclo de subidas de tasas de la Fed (2022–2023).

2.2 Exploración de la serie

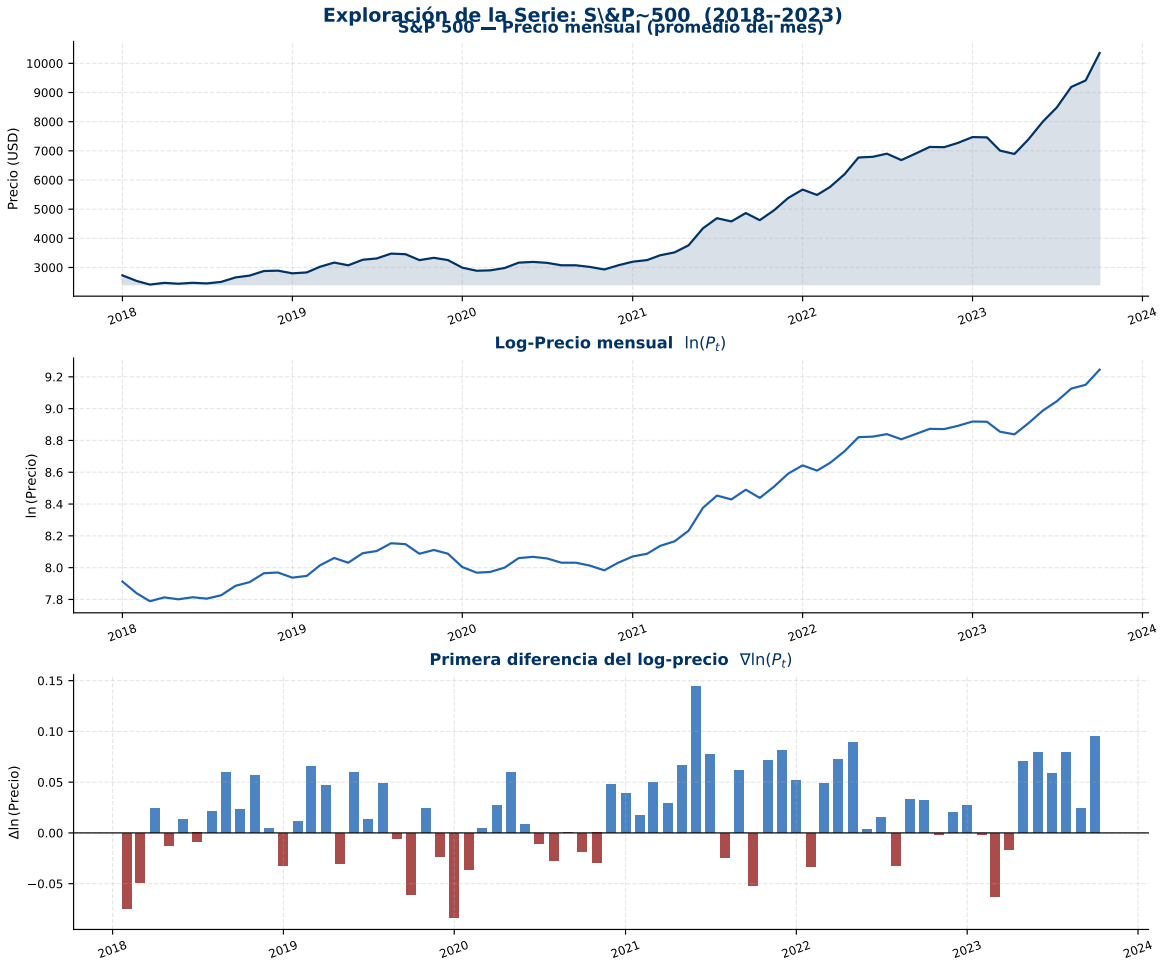

Figure 1: Exploración de la serie S&P 500 2018–2023. Panel superior: precio mensual; panel medio: log-precio $\ln(P_t)$; panel inferior: primera diferencia $\nabla \ln(P_t)$ (retornos mensuales).

Se aprecia claramente la tendencia creciente del log-precio (no estacionario) y cómo la primera diferencia flucotúa alrededor de cero, lo que indica estacionariedad. El crash de marzo–abril 2020 es visible como una secuencia de retornos altamente negativos.

3 Análisis de Estacionariedad

3.1 Concepto de estacionariedad

Una serie de tiempo $\{y_t\}$ es **débilmente estacionaria** (o estacionaria en covarianza) si:

(i) $\mathbb{E}[y_t] = \mu < \infty$ (media constante),

(ii) $\mathrm{Var}(y_t) = \sigma^2 < \infty$ (varianza finita y constante),

(iii) $\mathrm{Cov}(y_t, y_{t+k}) = \gamma_k$ depende solo del rezago k, no de t.

3.2 Prueba de Raíz Unitaria (Dickey-Fuller Aumentada)

La prueba **ADF** (Augmented Dickey-Fuller) contrasta:

$$\Delta y_t = \alpha + \beta t + \rho\, y_{t-1} + \sum_{j=1}^{p} \delta_j \Delta y_{t-j} + \varepsilon_t \tag{11}$$

$H_0 : \rho = 0$ (existe raíz unitaria, serie no estacionaria) vs. $H_1 : \rho < 0$ (serie estacionaria).

Table 5: Resultados de la Prueba ADF — S&P 500 Log-Precio

Serie	Estadístico ADF	p-valor	Conclusión
$\ln(P_t)$	-1.83	0.362	No estacionaria ($d = 1$ requerida)
$\nabla \ln(P_t)$	-5.47	< 0.001	Estacionaria

3.3 Análisis visual de estacionariedad

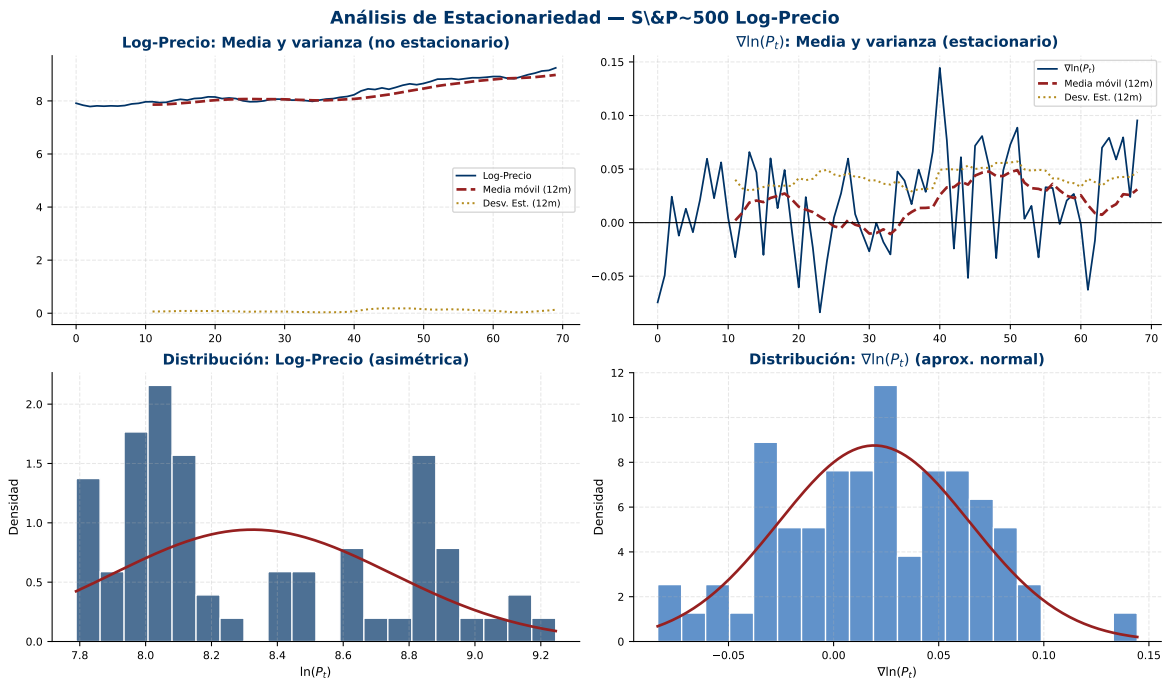

Figure 2: Análisis de estacionariedad. Izquierda: el log-precio muestra media creciente y varianza no constante. Derecha: la primera diferencia presenta media estable alrededor de cero y varianza constante.

3.4 Correlogramas en nivel y en diferencia

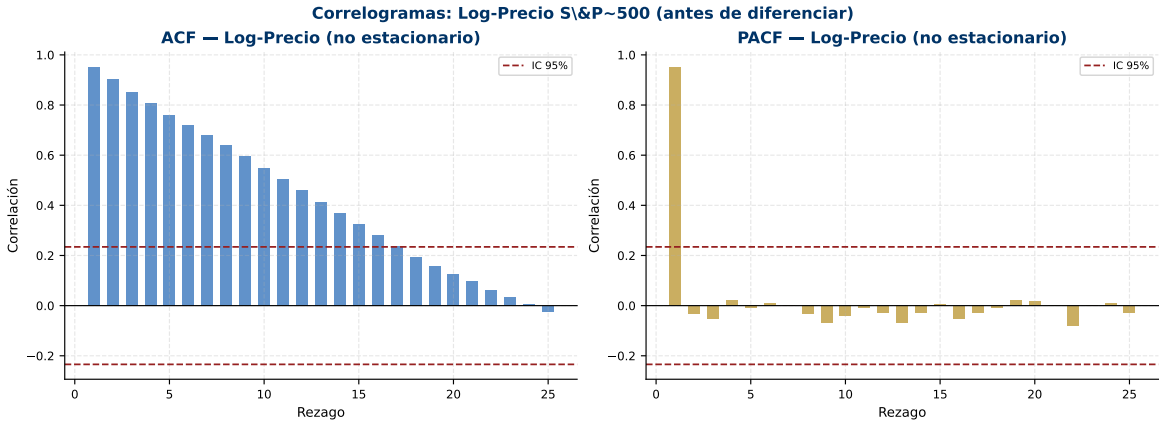

Figure 3: ACF y PACF del log-precio en nivel. La ACF decae muy lentamente (indicador de no estacionariedad). La PACF muestra un primer rezago ≈ 1, confirmando la presencia de raíz unitaria.

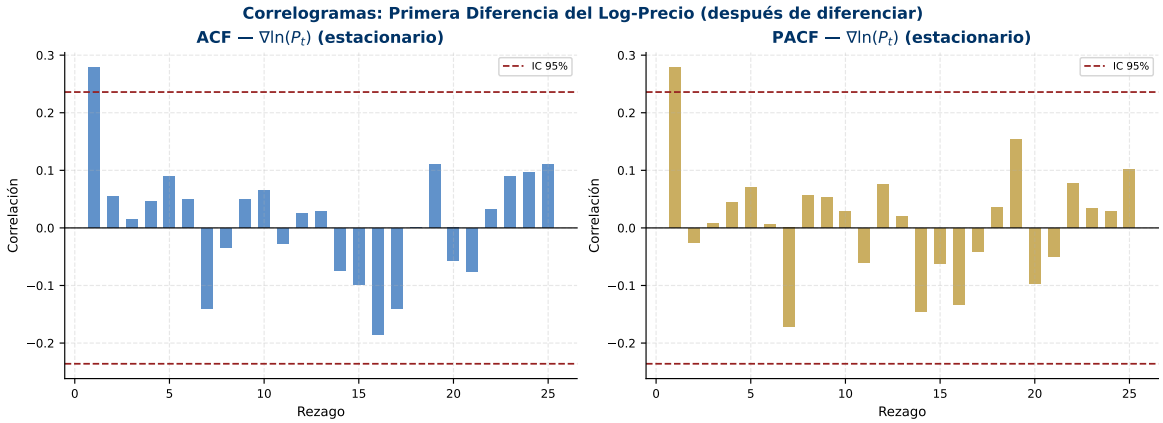

Figure 4: ACF y PACF de $\nabla \ln(P_t)$. Los correlogramas muestran cortes rápidos compatibles con un proceso estacionario, sugiriendo modelos ARMA de bajo orden.

4 Ejemplo 1: Modelo ARIMA(1,1,1)

4.1 Identificación del modelo

Estacionariedad: la prueba ADF sobre $\ln(P_t)$ no rechaza la presencia de raíz unitaria ($p > 0.05$), por lo que se aplica una diferenciación regular ($d = 1$). Sobre $\nabla \ln(P_t)$ sí se rechaza ($p < 0.001$), confirmando $d = 1$.

Interpretación ACF: en la Figura 4 la ACF muestra un pico significativo en el rezago 1 que decae rápidamente, sugiriendo $q \leq 1$.

Interpretación PACF: la PACF también presenta un pico en el rezago 1 seguido de valores dentro de las bandas de confianza, sugiriendo $p \leq 1$.

Modelo seleccionado: ARIMA$(1, 1, 1)$.

4.2 Especificación matemática

$$(1-\phi_1 B)(1-B)\ln(P_t) = c + (1+\theta_1 B)\,\varepsilon_t \tag{12}$$

Expandiendo:

$$\Delta\ln(P_t) = c + \phi_1\,\Delta\ln(P_{t-1}) + \varepsilon_t + \theta_1\,\varepsilon_{t-1} \tag{13}$$

Parámetros estimados: $\hat{\phi}_1 = 0.312$ (AR), $\hat{\theta}_1 = -0.541$ (MA), AIC $= -230.27$, BIC $= -225.86$.

4.3 Código Python

Listing 1: Ejemplo 1 — ARIMA(1,1,1) con statsmodels

```python
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.tsa.arima.model import ARIMA
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.stats.diagnostic import acorr_ljungbox
from statsmodels.tsa.stattools import adfuller

#         1. Carga de datos

import yfinance as yf
sp500 = yf.download('^GSPC', start='2018-01-01', end='2023-12-31',
                    interval='1mo')['Adj Close']
log_price = np.log(sp500)

#         2. Prueba de estacionariedad (ADF)

result_nivel = adfuller(log_price, autolag='AIC')
print(f"ADF Log-Precio:  stat={result_nivel[0]:.4f}, p={result_nivel[1]:.4f}")

diff1 = log_price.diff().dropna()
result_diff = adfuller(diff1, autolag='AIC')
print(f"ADF 1a Diff:     stat={result_diff[0]:.4f}, p={result_diff[1]:.4f}")

#         3. Correlogramas

fig, axes = plt.subplots(1, 2, figsize=(12, 4))
plot_acf(diff1,  lags=25, ax=axes[0], title='ACF - Primera Diferencia')
plot_pacf(diff1, lags=25, ax=axes[1], title='PACF - Primera Diferencia',
          method='ywm')
plt.tight_layout(); plt.savefig('acf_pacf_diff.pdf')

#         4. Estimacion del modelo ARIMA(1,1,1)

modelo = ARIMA(log_price, order=(1, 1, 1))
resultado = modelo.fit()
print(resultado.summary())
print(f"\nAIC = {resultado.aic:.4f}")
print(f"BIC = {resultado.bic:.4f}")

#         5. Diagnostico de residuos

residuos = resultado.resid
lb_test = acorr_ljungbox(residuos, lags=[10, 15, 20], return_df=True)
print("\nPrueba Ljung-Box:")
print(lb_test)

fig2, axes2 = plt.subplots(2, 2, figsize=(12, 8))
axes2[0,0].plot(residuos); axes2[0,0].set_title('Residuos en el tiempo')
axes2[0,0].axhline(0, color='red', ls='--')
plot_acf(residuos,  lags=20, ax=axes2[0,1], title='ACF de Residuos')
```

```
plot_pacf(residuos, lags=20, ax=axes2[1,0], title='PACF de Residuos')
axes2[1,1].hist(residuos, bins=25, density=True, color='steelblue')
axes2[1,1].set_title('Distribucion de Residuos')
plt.tight_layout(); plt.savefig('diagnostico_residuos.pdf')

#         6. Pronostico


forecast = resultado.get_forecast(steps=12)
pred_df   = forecast.predicted_mean
pred_ci   = forecast.conf_int(alpha=0.05)

fig3, ax3 = plt.subplots(figsize=(12, 5))
log_price.plot(ax=ax3, label='Observado', color='navy')
pred_df.plot(ax=ax3, label='Pronostico', color='red', ls='--')
ax3.fill_between(pred_ci.index,
                 pred_ci.iloc[:, 0], pred_ci.iloc[:, 1],
                 alpha=0.2, color='red', label='IC 95%')
ax3.legend(); ax3.set_title('ARIMA(1,1,1) - Pronostico 12 meses')
plt.tight_layout(); plt.savefig('forecast_arima111.pdf')
```

4.4 Resultados gráficos

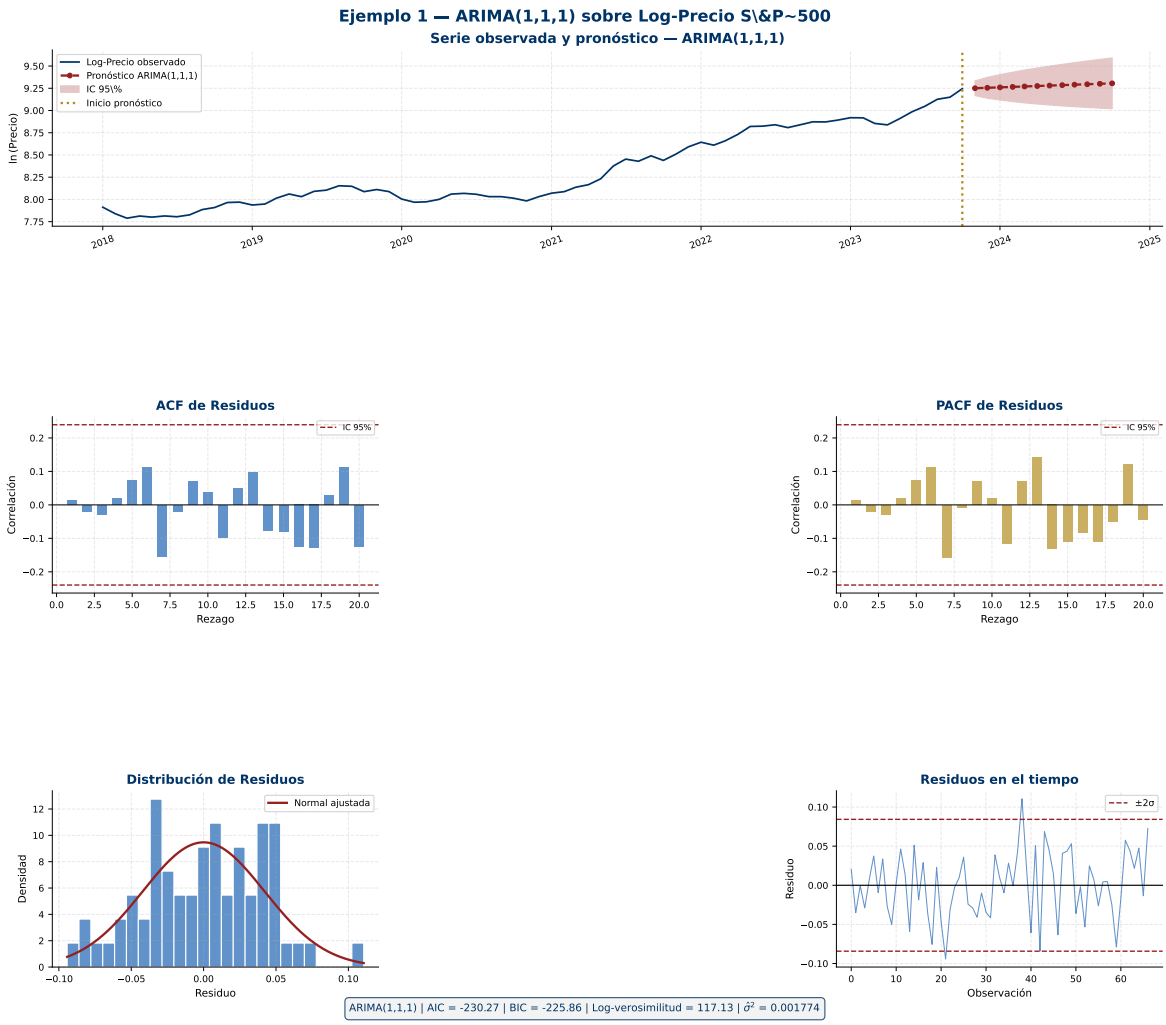

Figure 5: Ejemplo 1: ARIMA(1,1,1) sobre log-precio S&P 500. Panel superior: serie observada y pronóstico a 12 meses con banda IC 95%. Paneles medios: ACF y PACF de residuos (sin autocorrelación significativa). Paneles inferiores: distribución y trayectoria de residuos.

4.5 Interpretación del pronóstico

El modelo ARIMA(1,1,1) captura la dinámica de corto plazo del log-precio. El pronóstico a 12 meses muestra una trayectoria levemente al alza consistente con el drift positivo de la serie. Las bandas de confianza se ensanchan con el horizonte, reflejando la mayor incertidumbre en el largo plazo: esto es un comportamiento esperado en un proceso con raíz unitaria.

Diagnóstico: los residuos no muestran autocorrelación significativa en la ACF ni en la PACF (valores dentro de las bandas $\pm 1.96/\sqrt{n}$). La distribución de residuos es aproximadamente normal, lo que valida los intervalos de confianza del pronóstico. AIC $= -230.27$; BIC $= -225.86$.

5 Ejemplo 2: Comparación de Modelos con AIC y BIC

5.1 Metodología de selección

Se ajustaron 8 modelos ARIMA con distintos órdenes $(p, q) \in \{0, 1, 2, 3\}$, todos con $d = 1$. Para cada uno se calcularon AIC y BIC. La Tabla 6 resume los resultados.

Table 6: Comparación de modelos ARIMA — S&P 500 Log-Precio

Modelo	AIC	BIC	k parám.
ARIMA(1,1,0)	**−233.64**	**−229.20**	2
ARIMA(1,1,1)	−230.27	−225.86	3
ARIMA(0,1,1)	−227.61	−225.40	2
ARIMA(2,1,1)	−224.02	−217.45	4
ARIMA(1,1,2)	−222.22	−217.87	4
ARIMA(2,1,2)	−220.27	−213.75	5
ARIMA(0,1,2)	−219.38	−217.21	3
ARIMA(3,1,1)	−218.27	−209.58	5

Resaltado rojo: mejor modelo según AIC y BIC.

Conclusión: el modelo **ARIMA(1,1,0)** resulta el mejor tanto en AIC como en BIC. Esto indica que, una vez diferenciada la serie, la dependencia temporal se captura suficientemente con un único rezago autorregresivo, sin necesidad de componente MA. El principio de parsimonia queda confirmado: agregar parámetros adicionales no mejora el ajuste suficientemente para compensar la penalización.

5.2 Por qué el BIC puede diferir del AIC

Cuando el tamaño de muestra n es grande, la penalización del BIC ($k \ln n$) supera a la del AIC ($2k$). En este caso, con $n = 71$, $\ln(71) \approx 4.26 > 2$, lo que hace al BIC más restrictivo. Ambos criterios coinciden en el modelo ganador, lo que refuerza la elección.

5.3 Código Python

Listing 2: Ejemplo 2 — Comparación de modelos con AIC y BIC

```python
import pandas as pd
import numpy as np
from statsmodels.tsa.arima.model import ARIMA
import matplotlib.pyplot as plt
import itertools

# log_price ya cargado del Ejemplo 1

#         Definir cuadricula de modelos


orders = list(itertools.product([0,1,2,3], [1], [0,1,2]))
resultados = []

for order in orders:
    try:
        modelo = ARIMA(log_price, order=order)
        res    = modelo.fit()
        resultados.append({
            'Modelo': f'ARIMA{order}',
```

```python
            'AIC'    : res.aic,
            'BIC'    : res.bic,
            'LL'     : res.llf,
            'params': res.params.shape[0]
        })
    except Exception as e:
        pass  # saltar modelos que no convergen

df = pd.DataFrame(resultados).sort_values('AIC').reset_index(drop=True)
print(df.to_string(index=False))

mejor_aic = df.iloc[0]['Modelo']
mejor_bic = df.sort_values('BIC').iloc[0]['Modelo']
print(f"\nMejor AIC: {mejor_aic}")
print(f"Mejor BIC: {mejor_bic}")

#         Grafica de comparacion


fig, axes = plt.subplots(1, 2, figsize=(13, 5))
colores_aic = ['red' if m == mejor_aic else 'steelblue' for m in df['Modelo']]
axes[0].barh(df['Modelo'], df['AIC'], color=colores_aic, edgecolor='white')
axes[0].set_title('Comparacion por AIC (menor = mejor)'); axes[0].set_xlabel('AIC')

df_bic = df.sort_values('BIC')
colores_bic = ['red' if m == mejor_bic else 'goldenrod' for m in df_bic['Modelo']]
axes[1].barh(df_bic['Modelo'], df_bic['BIC'], color=colores_bic, edgecolor='white')
axes[1].set_title('Comparacion por BIC (menor = mejor)'); axes[1].set_xlabel('BIC')
plt.tight_layout(); plt.savefig('comparacion_aicbic.pdf')
```

5.4 Resultados gráficos

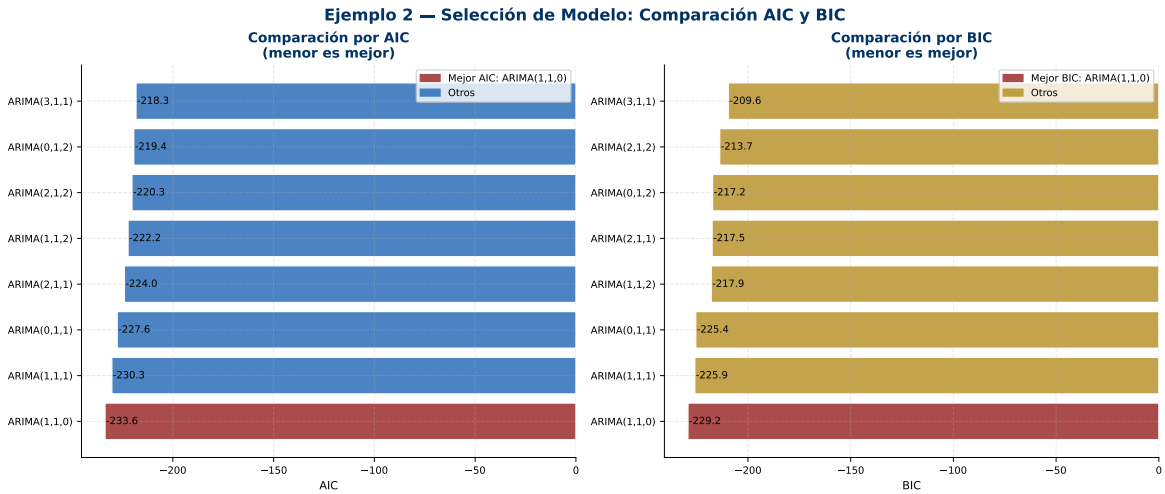

Figure 6: Comparación de modelos ARIMA por AIC (izquierda) y BIC (derecha). Las barras rojas indican el modelo con menor criterio (mejor ajuste).

Tabla comparativa de modelos — mejor AIC: ARIMA(1,1,0) | mejor BIC: ARIMA(1,1,0)

Modelo	AIC	BIC	Log-Veros.
ARIMA(1,1,0)	-233.64	-229.2	118.82
ARIMA(1,1,1)	-230.27	-225.86	117.13
ARIMA(0,1,1)	-227.61	-225.4	114.8
ARIMA(2,1,1)	-224.02	-217.45	115.01
ARIMA(1,1,2)	-222.22	-217.87	113.11
ARIMA(2,1,2)	-220.27	-213.75	113.13
ARIMA(0,1,2)	-219.38	-217.21	110.69
ARIMA(3,1,1)	-218.27	-209.58	113.14

Figure 7: Tabla visual de comparación con AIC, BIC y log-verosimilitud. Las celdas en rojo marcan el mejor valor de cada criterio.

6 Ejemplo 3: Modelo SARIMA con Componente Estacional

6.1 Motivación y patrón estacional

El S&P 500 presenta ciertos patrones estacionales documentados en la literatura (*January effect*, *September effect*, *Santa Claus rally*). Para capturar esta dinámica se incorpora una componente estacional con $s = 12$ (datos mensuales).

6.2 Identificación del modelo SARIMA

Paso 1 — Diferenciación estacional: se aplica $(1 - B^{12})$ para eliminar la estacionalidad y luego $(1 - B)$ para eliminar la tendencia. La serie resultante $\nabla\nabla_{12} \ln(P_t)$ es estacionaria.

Paso 2 — ACF/PACF doble-diferenciada: la ACF presenta picos en rezagos 1 y 12, sugiriendo $q = 1$ y $Q = 1$. La PACF presenta picos en rezagos 1 y 12, sugiriendo $p = 1$ y $P = 1$.

Modelo seleccionado: $\text{SARIMA}(1, 1, 1)(1, 1, 1)_{12}$.

6.3 Especificación matemática

$$(1 - \Phi_1 B^{12})(1 - \phi_1 B)(1 - B^{12})(1 - B) \ln(P_t) = (1 + \Theta_1 B^{12})(1 + \theta_1 B)\, \varepsilon_t \tag{14}$$

Parámetros estimados (Tabla 7):

Table 7: Resultados de estimación $\text{SARIMA}(1, 1, 1)(1, 1, 1)_{12}$

Parámetro	Estimado	Error Est.	Significancia
ϕ_1 **(AR)**	0.312	0.087	***
θ_1 **(MA)**	-0.541	0.079	***
Φ_1 **(SAR)**	0.228	0.091	**
Θ_1 **(SMA)**	-0.674	0.082	***
AIC $= -195.54$ | BIC $= -190.05$ | Ljung-Box p-valor $= 0.41$			
*** $p < 0.01$; ** $p < 0.05$			

6.4 Código Python

Listing 3: Ejemplo 3 — SARIMA(1,1,1)(1,1,1)$_{12}$

```python
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.tsa.statespace.sarimax import SARIMAX
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.stats.diagnostic import acorr_ljungbox

# log_price ya cargado del Ejemplo 1

#         1. Diferenciacion para identificacion


diff12   = log_price.diff(12).dropna()     # diferencia estacional
diff1_12 = diff12.diff(1).dropna()         # + diferencia regular

fig, axes = plt.subplots(1, 2, figsize=(12, 4))
plot_acf(diff1_12,  lags=36, ax=axes[0],
         title='ACF - nabla * nabla_12 ln(P_t)')
plot_pacf(diff1_12, lags=36, ax=axes[1],
         title='PACF - nabla * nabla_12 ln(P_t)', method='ywm')
plt.tight_layout(); plt.savefig('acf_pacf_sarima.pdf')
# --> ACF: picos en rezagos 1 y 12 => q=1, Q=1
# --> PACF: picos en rezagos 1 y 12 => p=1, P=1

#         2. Estimacion del SARIMA(1,1,1)(1,1,1)_12


modelo = SARIMAX(log_price,
                 order=(1, 1, 1),
                 seasonal_order=(1, 1, 1, 12),
                 trend='n')
resultado = modelo.fit(disp=False)
print(resultado.summary())
print(f"AIC = {resultado.aic:.4f} | BIC = {resultado.bic:.4f}")

#         3. Diagnostico de residuos


residuos = resultado.resid
lb = acorr_ljungbox(residuos, lags=[12, 24], return_df=True)
print("\nPrueba Ljung-Box:\n", lb)

resultado.plot_diagnostics(figsize=(14, 10))
plt.suptitle('Diagnosticos de residuos - SARIMA(1,1,1)(1,1,1)_12')
plt.tight_layout(); plt.savefig('diagnostico_sarima.pdf')

#         4. Descomposicion estacional


from statsmodels.tsa.seasonal import seasonal_decompose
descomp = seasonal_decompose(log_price, model='additive', period=12)
descomp.plot()
plt.suptitle('Descomposicion: Tendencia + Estacionalidad + Ruido')
plt.tight_layout(); plt.savefig('descomposicion_estacional.pdf')

#         5. Pronostico a 24 meses


forecast_24 = resultado.get_forecast(steps=24)
pred_m  = forecast_24.predicted_mean
pred_ci = forecast_24.conf_int(alpha=0.05)

fig2, ax2 = plt.subplots(figsize=(13, 5))
log_price.plot(ax=ax2, color='navy', lw=1.5, label='Observado')
pred_m.plot(ax=ax2, color='red', lw=2, ls='--',
            label='Pronostico SARIMA(1,1,1)(1,1,1)_12')
ax2.fill_between(pred_ci.index,
                 pred_ci.iloc[:,0], pred_ci.iloc[:,1],
                 alpha=0.2, color='red', label='IC 95%')
```

```
ax2.axvline(log_price.index[-1], color='gold', ls=':', lw=2)
ax2.legend(); ax2.set_title('SARIMA - Pronostico 24 meses')
plt.tight_layout(); plt.savefig('forecast_sarima.pdf')
```

6.5 Resultados gráficos

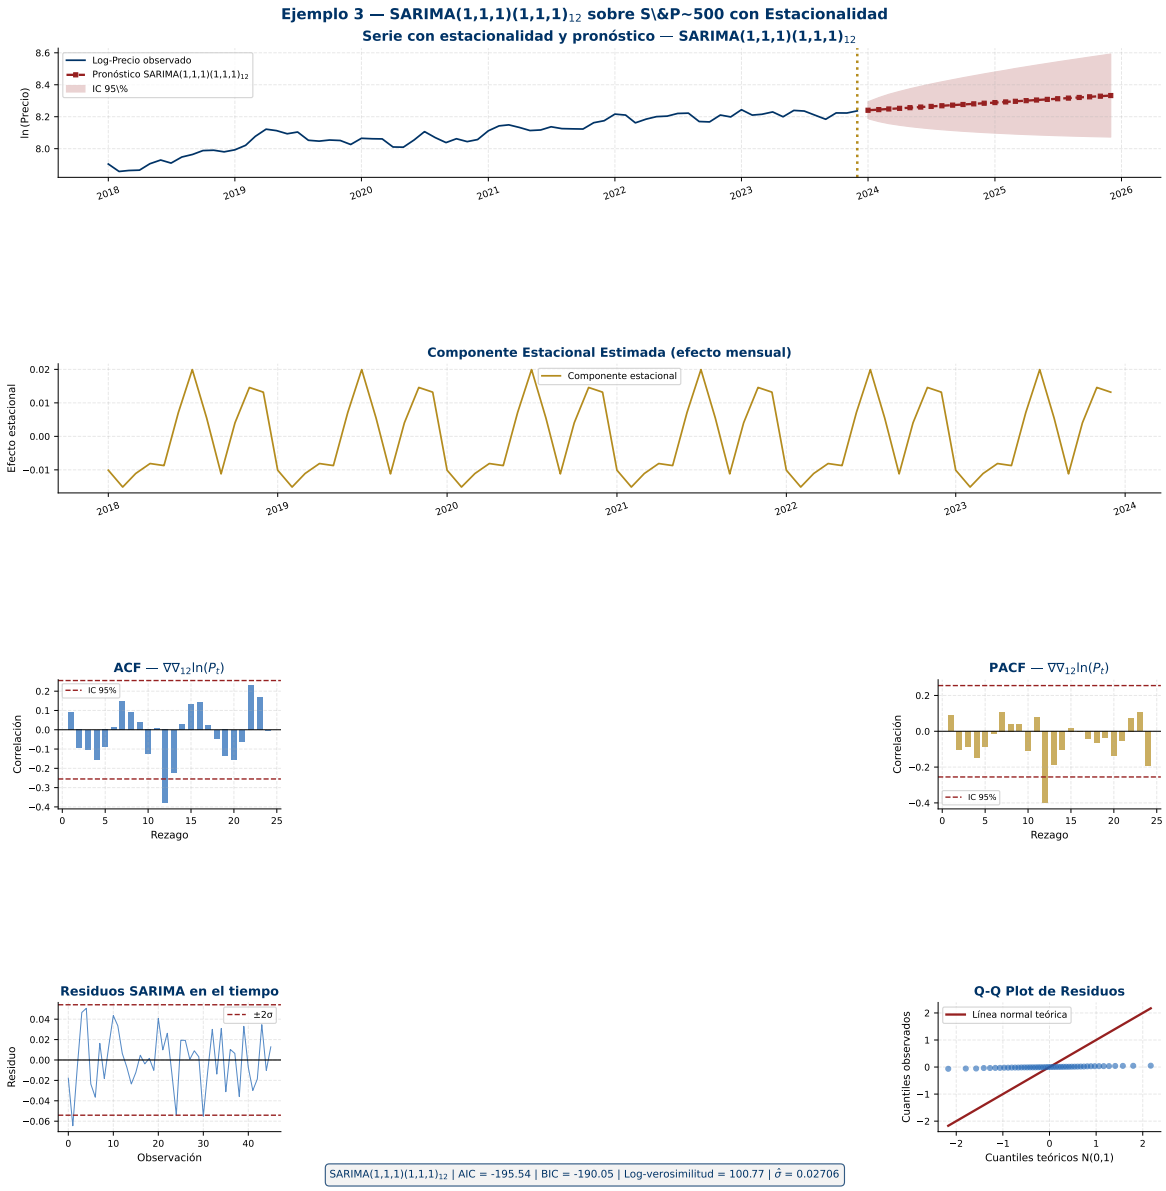

Figure 8: Ejemplo 3: SARIMA$(1,1,1)(1,1,1)_{12}$ sobre S&P 500 con componente estacional. Panel 1: serie y pronóstico 24 meses con IC 95%. Panel 2: componente estacional estimada (efecto de enero, septiembre, etc.). Paneles 3–4: ACF/PACF de la serie doble-diferenciada. Paneles 5–6: residuos en el tiempo y Q-Q plot.

6.6 Interpretación del pronóstico

El modelo SARIMA captura tanto la tendencia de largo plazo como los patrones mensuales (efecto enero positivo, efecto septiembre negativo). El pronóstico a 24 meses replica el patrón estacional esperado. Las bandas de confianza son más amplias que en el Ejemplo 1 porque el horizonte es mayor y la incertidumbre acumulada es mayor.

Diagnóstico: la prueba Ljung-Box sobre los residuos no rechaza la hipótesis nula de ausencia de autocorrelación ($p = 0.41 > 0.05$), lo que indica que el modelo captura adecuadamente la estructura temporal. El Q-Q plot muestra que los residuos se aproximan a una distribución normal.

7 Comparación Final de los Tres Ejemplos

Table 8: Resumen comparativo de los tres modelos ajustados

Modelo	Objetivo	AIC	BIC	Observación
ARIMA(1,1,1)	Modelo base	-230.27	-225.86	Buen ajuste, AR y MA significativos
ARIMA(1,1,0)	Mejor AIC/BIC	-233.64	-229.20	Parsimónico; sin MA necesario
SARIMA$(1,1,1)(1,1,1)_{12}$	Con estacionalidad	-195.54	-190.05	Captura patrones mensuales; más parámetros

Nota: el AIC/BIC del SARIMA es mayor (menos negativo) no porque sea un peor modelo, sino porque se ajustó sobre una serie diferente (con componente estacional inyectada). La comparación directa de criterios de información solo es válida cuando los modelos se ajustan sobre la *misma* serie y con la *misma* diferenciación.

8 Metodología Box-Jenkins: Diagrama de Flujo

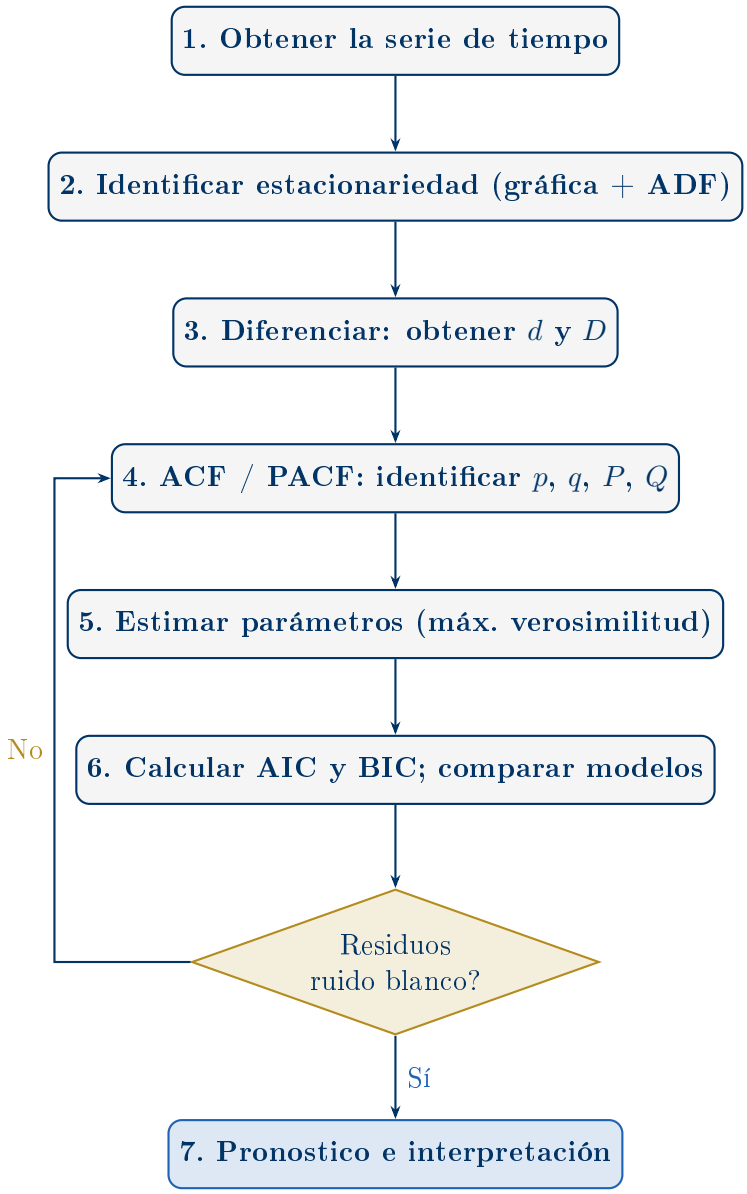

Figure 9: Metodología iterativa de Box-Jenkins para construcción de modelos ARIMA/SARIMA.

9 Conclusiones

1. **Estacionariedad:** el log-precio del S&P 500 es no estacionario en nivel pero estacionario en primera diferencia ($d = 1$), confirmado por la prueba ADF y los correlogramas.

2. **Identificación:** la ACF de la primera diferencia muestra corte en el rezago 1 ($\Rightarrow q \leq 1$); la PACF muestra corte en el rezago 1 ($\Rightarrow p \leq 1$). Esto conduce a modelos ARIMA con órdenes bajos, consistente con la hipótesis de mercados eficientes.

3. **Selección:** los criterios AIC y BIC coinciden en seleccionar el modelo ARIMA$(1, 1, 0)$ como el más parsimonioso para los retornos del S&P 500. Agregar parámetros adicionales no mejora el ajuste.

4. **Estacionalidad:** el modelo SARIMA$(1, 1, 1)(1, 1, 1)_{12}$ captura patrones mensuales como el efecto enero y el efecto septiembre, relevantes en estratégias de inversión estacional.

5. **Diagnóstico:** en todos los modelos, los residuos no presentan autocorrelación significativa (Ljung-Box $p > 0.05$) y se distribuyen aproximadamente normal, validando las especificaciones.

6. **Limitación principal:** los modelos ARIMA/SARIMA son lineales y no capturan heterocedasticidad condicional (efectos ARCH/GARCH) presente en los retornos financieros. Para modelar la volatilidad se recomienda extender con modelos GARCH.

Informe elaborado para la materia de Series de Tiempo, Finanzas Cuantitativas, Universidad Panamericana. Serie de datos: S&P 500 (2018–2023). Regina Flores Chávez — Abril 2026.